Understanding Variational Autoencoders' Latent Representations of Remote Sensing Images

Hannes Stärk

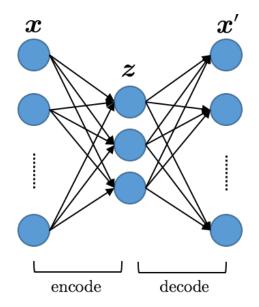
September 15, 2019

Gliederung

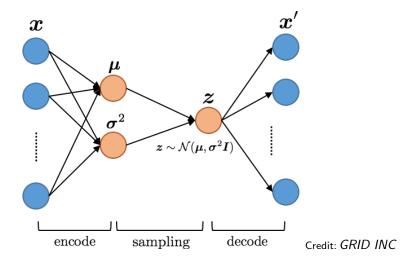
- Motivation
- Vorwissen
- ► Implementierung, Hardware, Software
- Datensatz
- Architekturen
- Architektur Experimente
- Latenter Raum Experimente
- Fazit, Wie kann es weiter gehen

Motivation

- ► Trial-and-Error Multi-Task Architekturen
- Multi-Task Taxonomie
- ► Latente Informationen einzelner Schichten in Single-Task Modellen
- Latenten Raum eines Variational Autoencoders verstehen



Credit: GRID INC

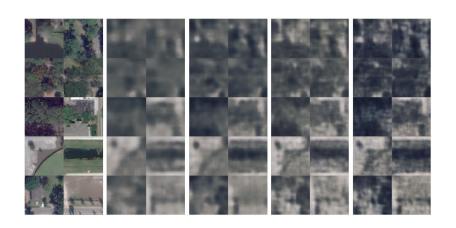


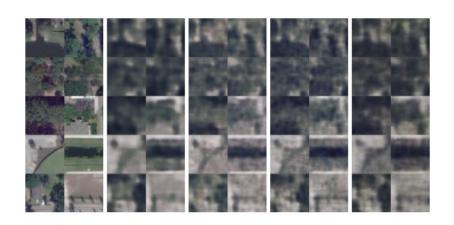
Implementierung, Hardware, Software

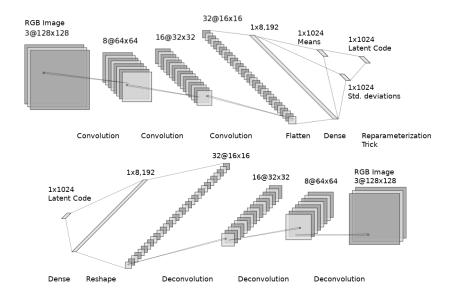
- Python
- Tensorflow
- Container der Uni Hannover
- ► Machine-Learning Rechner der UniBw

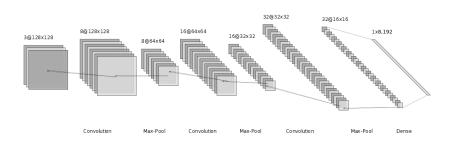
Architektur Experimente

- ► Anzahl von convolutional Schichten
- Anzahl von Filtern
- ► Kernel Größe
- ▶ Max/Average Pooling









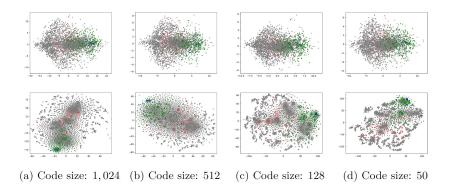


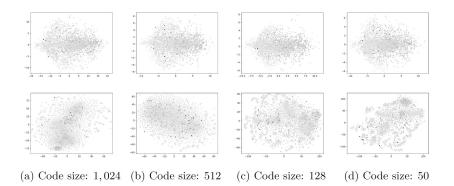
Latenter Raum Experimente

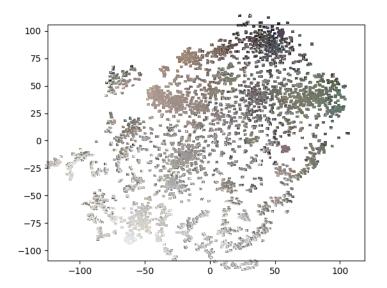
- ▶ 4000 Bilder => 4000 Encodings
- Dimension reduzieren
- Visualisieren

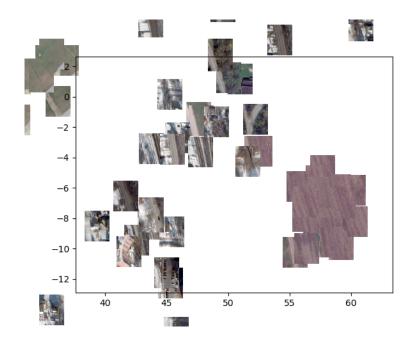
t-Stochastic-Neighbor-Embedding

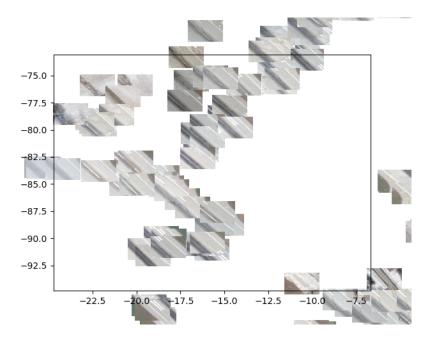
- ► Machine-Learning Verfahren zur Dimensions Reduktion
- Besonders gut geeignet für einzelne Visualisierungen
- Fokus auf Kontext von Punkten zu ihren Nachbarn











Fazit und wie es weiter gehen kann

- ▶ Der VAE lernt nach komplizierten Features zu clustern
- ▶ Mit t-SNE kann man die Cluster gut visualisieren
- Gute Rekonstruktionen vs. Guter Latenter Raum?
- Präzisere Methoden um Cluster zu Features zuzuordnen
- ► Als nächstes bei anderen Tasks als bei Autoencodern testen